元データを削除できた計算例

架空の設備ログによる三評価と削除後の再学習確認

2026年10月19日 第1版

事前に定めた条件を満たす例として、学習用の元データ1,632事例のうち、余剰の典型データ1,221事例を実験用保管領域から削除した。学習用元データのCSV容量は74.82%減少し、全1,632事例分の出現情報と正解は維持した。

評価または操作	実行結果
統計的な確立度	3パターンと2運転条件の6組が、今回の例示基準に合格
機械学習の代替可能性	典型の検証3,600事例で、元データ側と出現情報側の判定が全件一致
保持構成	114区分をすべて維持。典型219事例と境界120事例、未知72事例を保持
実際の削除	生成した学習用CSV 1,221ファイルを削除し、不在と履歴を確認
削除後の再学習	出現情報だけで再学習。削除前の出現情報モデルと判定・出力値が一致

この結果が示す範囲

繰り返しが多く、判定に必要な情報を要約に残せるよう設計した架空データの例である。正常・異常ラベルも人工的に生成している。実設備での削除可否、将来の性能、数学的な最小保持数、発明の新規性を実証した結果ではない。

削除許可は典型P0・P1・P2と標準負荷・高負荷の範囲に限定した。境界・未知については代替性の合格とは扱わず、元データを全件保持した。前の30秒ログの不合格例は変更していない。

1 ログの生成条件とデータの分離

一つの運転事例を60秒、観測間隔を1秒とし、振動と温度を記録した。各事例の開始間隔は2分で、元の観測点を共有しない。設備IDはMOTOR_DEMOの一種類であり、複数実設備での再現性を検証したものではない。

用途	典型	境界	未知	合計
パターン抽出とモデル学習	1440	120	72	1632
確立度評価	1440	120	72	1632
最終性能評価	3600	120	72	3792

学習、確立度評価、最終性能評価には別々の乱数系列を使用した。各集合には標準負荷・高負荷と3つの生成期間を含む。パターン中心の抽出とモデルの標準化・学習には学習集合だけを使う。最終評価結果を見て入力項目・閾値・モデル係数を調整していない。

生成項目	設定
安定P0	大きな上昇なし。正常側のラベル確率90%
短時間差P1	振動上昇の5・6・7秒後に温度上昇。異常側のラベル確率90%
長時間差P2	振動上昇の13・14・15秒後に温度上昇。正常側のラベル確率90%
境界候補	時間差9秒または11秒。異常側確率はそれぞれ60%または40%
未知候補	温度が6秒先行、または振動だけが上昇。異常側確率20%
典型内の変動	開始4〜7秒、振動継続18・20・22秒。振幅・基準値と観測雑音も変動

これらの生成種類は正解監査用であり、モデル入力には渡していない。元ログの数値を解析して事象を検出し、学習ログの時間差から中心を求める。ただし、未知の実設備から有用な状態を自律発見した証拠にはならない。

再計算用乱数の種は学習20261019、確立度20262019、最終評価20263019。
protocol_frozen_before_data.jsonに、生成前の設定と三評価の条件を保存した。

2 元ログから事象とパターンを作る

検出条件は人が設定した。各事例冒頭3点の中央値を基準とし、振動は基準＋2.0 mm/s、温度は基準＋3.0℃以上が3点連続した場合に上昇とする。開始時刻は連続列の最初の点で、確定は2秒後となる。

保持した実例 TRAIN_00029 では、振動の開始6秒、温度の開始11秒、時間差5秒、振動継続20秒となった。

経過秒	振動 mm/s	温度 ℃
0	1.2024	44.8888
2	1.1734	44.9242
5	1.2012	44.8628
6	5.5065	44.8948
10	5.4850	44.9302
11	5.4722	52.3429
13	5.5084	52.3339
25	5.4941	52.2994
26	1.2226	52.3469

時間差の中心を学習ログから求める

両事象がある学習事例の非負時間差について、各整数秒の頻度が対象の8%以上となる値を選ぶ。この頻度条件は設定である。選んだ値をDBSCANの近傍距離1.01秒、最小点数20で集約し、群ごとの中央値6秒と14秒を得た。ラベルはこの抽出に使わない。

中心からの時間差のずれが1.05秒以内なら典型、3.05秒以内なら境界、それを超えるものや片方の事象だけのものは未知とした。両チャネルの変動幅が0.5以下の完全観測事例を安定P0とする規則も設定した。

温度が事例終端まで高い場合、温度の継続時間は60秒の観測範囲内の時間である。事象そのものが終了した時刻や、完全な継続時間を求めたという意味ではない。

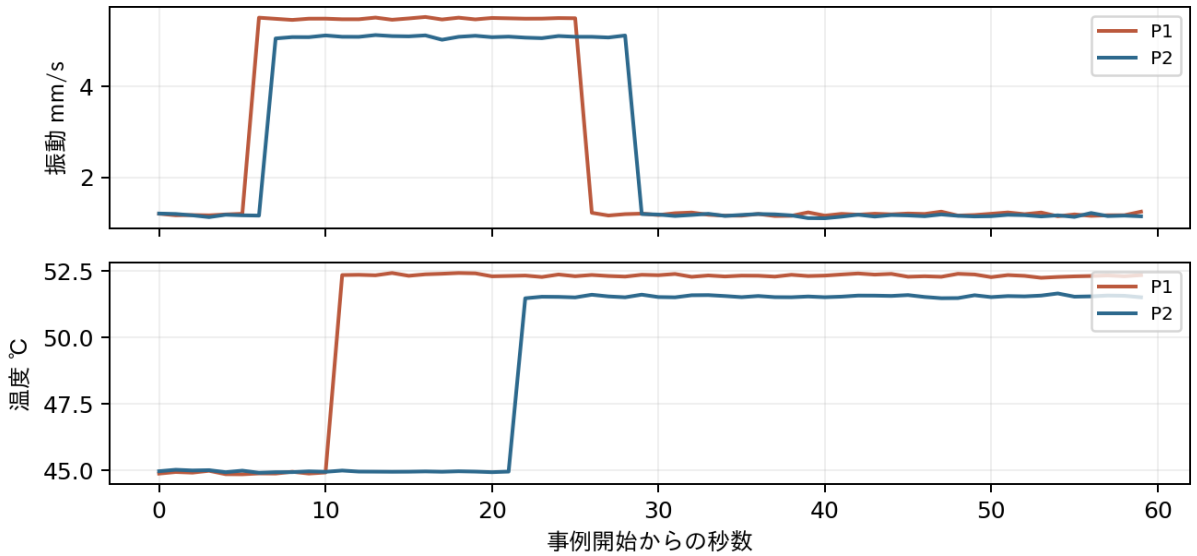
3 モデルへ渡した情報

元データ側は、振動60点と温度60点の計120項目を使う。出現情報側は下表の12項目を使い、いずれもStandardScalerとロジスティック回帰で学習した。正則化設定C=1、判定閾値0.5、学習上限2,000回は事前設定である。

入力位置	出現情報側の入力	意味
1〜3	P0・P1・P2の典型出現の有無	1事例に各種類は高々1回なので、0・1の有無と回数が一致
4〜5	境界あり・未知あり	典型に分類できなかった状況を区別
6〜7	符号付き時間差・計算可能フラグ	時間差が計算できない場合の0を、真の0秒と区別
8〜9	振動継続・温度の観測内継続	単位は秒。温度は事例終端で打ち切った長さ
10〜11	振動上昇量・温度上昇量	基準値との差。単位はmm/sと℃
12	高負荷フラグ	今回の運転条件。元データ側にも負荷に応じた基準値の違いが含まれる

判定対象ごとに1行を生成し、学習用の全1,632行を使った。削除対象が多いパターンほど行を間引いたり、代表波形を出現回数分コピーしたりしていない。事例ごとの正解と条件も保持する。全履歴の累積出現回数を、各事例の入力に加える処理ではない。

特徴量の標準化はそれぞれ学習集合で求め、最終評価では固定した。モデルの入力位置とパターン版はregistry.jsonで管理し、IDや正解ラベルを数値入力にしていない。



保持したP1とP2の元波形の例。値は実験用に生成したもので、実設備の計測ではない。

4 統計的な確立度の評価

確立度用の別集合で、パターン・負荷ごとの出現数、時間差の安定性、期間ごとの再現性、ラベルとの関係を評価した。これは本実験の合格基準であり、実運用にそのまま採用する値ではない。

確認項目	今回の合格条件
出現数	各パターン・負荷・生成期間で60事例以上
時間差の不確かさ	P1・P2の期間別平均について、t区間による95%区間の半幅が0.25秒以下
期間による変動	期間別平均の最大差が0.5秒以下。P0は振動基準値の平均差0.1以下
正常異常との関連の安定性	パターン内の異常割合のWilson 95%区間幅0.13以下、各期間で多数側が同じ

定義	負荷	事例数	異常数	異常割合の95%区間	判定
P0	標準	240	28/240	8.20%〜16.34%	合格
P0	高負荷	240	27/240	7.85%〜15.87%	合格
P1	標準	240	216/240	85.55%〜93.19%	合格
P1	高負荷	240	216/240	85.55%〜93.19%	合格
P2	標準	240	27/240	7.85%〜15.87%	合格
P2	高負荷	240	24/240	6.81%〜14.45%	合格

P1の標準負荷は216/240＝90.0%、区間は85.55〜93.19%。P2の標準負荷は27/240＝11.25%となった。「典型」は正常を意味せず、P1にも正常ラベルの事例が含まれる。

P1の期間別平均時間差の最大差は標準0.100秒、高負荷0.325秒。P2は標準0.063秒、高負荷0.188秒であった。期間別平均の95%区間半幅の最大は0.196秒で、設定した0.25秒以内だった。

信頼区間は、生成した事例の独立性等を前提に計算している。期間を人工的に分けても、実設備の経年変化・設備差・季節差の確認を代替しない。各Wilson区間を同時95%区間と主張するものでもない。

5 代替可能性の評価と適用範囲

範囲	件数	元 異常検出率	代替 異常検出率	元 正常判定率	代替 正常判定率
典型全体	3600	82.57%	82.57%	94.97%	94.97%
標準負荷	1800	82.04%	82.04%	95.41%	95.41%
高負荷	1800	83.13%	83.13%	94.54%	94.54%

典型3,600事例では、異常1,314件中1,085件を検出し、正常2,286件中2,171件を正常と判定した。両モデルとも正解率90.44%、異常検出率82.57%、正常判定率94.97%で、判定の相違は0件だった。

差が0でも不確かさを0とはしない

基準モデルが正解し代替モデルが誤った事例を「悪化」と数え、改善は差し引かない。この悪化率の片側上限を、性能低下の保守的な上限として使った。全体と負荷別の検出率・正常判定率の6項目、パターンと負荷別の判定不一致率6項目を確認した。

12個の上限が真の率を下回る確率の合計を5%以内に抑える設定として各項目のαを0.05/12とし、二項比率のClopper–Pearson片側上限を計算した。今回の独立性・評価分布の仮定での確認であり、将来や別分布まで保証するものではない。

確認項目	件数または範囲	片側上限の最大	基準
検出率の悪化	全体・標準・高負荷	0.845ポイント	2ポイント以下
正常判定率の悪化	全体・標準・高負荷	0.483ポイント	2ポイント以下
判定不一致	3パターン×2負荷、各600件	0.909%	2%以下

境界・未知を含む全3,792件では、元データ側の異常検出率80.36%に対し、出現情報側は78.62%であった。境界・未知への代替性を確認済みとは扱わず、削除許可の対象から外した。将来の運用でモデルをどう使い分けるかは別途設計が必要で、切替処理を実装した結果ではない。

今回の合格は分類判定を対象にしている。二つのモデルの確率値そのものや確率校正、回帰性能の同等性を確認したわけではない。

6 保持集合の選定と削除対象

学習用の典型1,440件を、パターン・負荷・生成期間・整数時間差・振動継続時間で区分した。P1・P2は時間差3種類×継続3種類を含み、P0には時間差がない専用の区分を置く。観測された114区分それぞれから最低1件を選んだ。

さらに各パターン・負荷・期間で、代表例、直近2件、振動上昇量・温度上昇量・振動開始時刻の最小最大を含む例を追加した。重複した事例IDは一つとして数える。結果として典型219件を保持し、残り1,221件を削除候補とした。

分類	負荷	削除前	保持	削除
P0	標準	240	9	231
P0	高負荷	240	9	231
P1	標準	240	50	190
P1	高負荷	240	50	190
P2	標準	240	50	190
P2	高負荷	240	51	189
境界	両条件	120	120	0
未知	両条件	72	72	0
合計		1632	411	1221

総数だけを満たしても合格させない

対照として、典型219件という同じ総数を標準負荷だけから選ぶと、必要な区分95個が欠けた。うち57区分は高負荷の区分であり、不合格となった。これは実際に区分別件数を数えて確認した結果である。

今回の必要数は「観測済み区分を少なくとも1件ずつ残し、指定の代表・最近・極値を残す」という例示規則から定まる。将来の再構築に数学的に十分な数、あるいは最小の保持数を算出したという意味ではない。保持集合だけからパターン定義を再抽出する追加案は、この実験では実行していない。

7 削除の実行と削除後の確認

三評価がすべて合格した場合だけ、保持集合外の典型学習CSVを対象に削除を実行した。対象は今回生成した実験ファイルに限定し、削除前に内容のSHA256を確認した。事例ID・定義・条件・元の保存先・容量・ハッシュ・許可番号を履歴に残した。

確認対象	結果
削除対象の不在	1,221件すべての元CSVが実験用保管領域に存在しない
保持対象の存在	典型219件、境界120件、未知72件の計411件が存在
元データ参照の更新	削除済み事例の現行保存先は空にし、状態をdeletedへ更新
履歴と内容	保持ファイルのハッシュが一致。削除履歴に件数と元ハッシュを保存
過去の出現情報	1,632事例分の入力生成用記録と正解が残存。履歴件数は変化なし
再学習	削除済みCSVを読まず、保存記録だけで同じ構成を学習できた
再学習後の出力	元の出現情報モデルとの判定一致、最大確率差0.0
統計説明	確立度評価集合の統計と、学習集合の分類別履歴件数が削除前後で一致

保存した学習記録からの再学習は、代表元データを出現回数分コピーする処理ではない。各事例の出現情報をそのまま使用したため、削除前後で入力行と正解の対応を維持できた。

例えば学習用のP1の典型出現は、削除後に元CSVが100件になっても、過去の出現数480件のままである。残存元データ100件だけを分母として過去の出現数や統計を取り直していない。

verify_after_deletion.pyを別に実行し、ファイルの存在・不在、保持内容、参照、件数、二項上限12項目、保存モデルの出力を監査した。監査のために削除済み元データを再生成していない。

確立度評価用と最終評価用の元データは監査・比較のため全件保持している。学習用元データの削減率と、実験全体の保存量を混同しない。削除済みデータを、稼働中の仕組みで復元できるという主張でもない。

8 保存量と判定説明の具体例

対象	削除前	削除後	削減
学習用 元CSV	7.470 MB	1.881 MB	74.82%
全用途の元CSV	34.671 MB	29.083 MB	16.12%
学習用 出現情報等のCSV	別途保存	0.480 MB	削除しない

MBは1,000,000バイト。上表の削減率は元CSVの実測ファイル容量であり、知識ベース・モデル・履歴・索引等を含むシステム全体の削減率ではない。評価用元CSVも残るため、全用途の元CSVの削減率は約16.12%である。

同じパターン版から判定と統計を説明する

説明例としてVERIFICATION_00003を選ぶ。振動開始は5秒、温度開始は12秒、時間差は7秒で、P1第1版の典型に一致した。モデル入力は下記で、学習したモデルの判定値は2.010374、出力は0.881882となり、0.5以上のため異常側と判定した。

入力群	実際の値
P0・P1・P2の有無	0, 1, 0
境界・未知の有無	0, 0
時間差・計算可能	7秒, 1
振動継続・温度の観測内継続	22秒, 48秒
振動上昇量・温度上昇量	3.7621 mm/s, 7.2059 ℃
高負荷	0

過去の別集合では、同じP1第1版・標準負荷の240事例中216件が異常ラベルで、異常割合90.0%、Wilson 95%区間85.55〜93.19%だった。この履歴統計をモデル出力と分けて提示できる。

モデル出力88.19%は、この架空データで学習した値であり、校正済みの実設備故障確率ではない。過去の90.0%も今回の判定の直接の計算式や、異常原因の証明ではない。

9 不合格となる例と残る課題

情報を落としすぎると削除できない

対照モデルは「振動上昇あり・温度上昇あり・高負荷」の3項目だけを入力した。P1とP2はどちらも両事象があるため、時間差の重要な違いを失う。典型3,600件の異常検出率は0.0%、正解率は63.50%で、代替可能性評価は不合格となった。

この対照は、出現回数や有無を入力すれば必ず十分という考えを否定する例である。成功した12項目では、時間差や継続時間等も残している。ただし12項目が最小・最適と検証したものではない。

今回確認できたこと

抽出・分類、出現情報の保持、二つのモデルの比較、条件別の削除許可、保持集合の選定、生成CSVの削除、参照更新、出現情報からの再学習、履歴統計の維持を一つの計算例として実行した。

今回確認していないこと

実設備での事象検出と正解ラベルの妥当性、複数設備への再現性、分布変化後の性能、欠測・遅延・同時更新への運用対応は未検証である。特に本例は1事例内に同じ種類の上昇が高々1回で、複数事象の対応づけを簡略化している。

保持集合だけからのパターン再抽出、将来未知パターンの発見、元データの完全復元は確認していない。変化検知から削除停止・再構築・再開までの一連処理も本実験の対象外である。旧版や別条件へ許可を自動適用する仕組みではない。

本例の合否閾値、保持区分、使用特徴量は実装候補の具体例であり、既存の6項の技術事項にすべて採用済みという意味ではない。これら既存手法の組合せを実行できたことだけで、新規性・進歩性が確認されたとはいえない。

次に実設備で検証する場合

実運転の周期・正解・条件を定めて同じ比較を行い、代表性のある別期間・別設備で性能差と保持構成を評価する。見逃し等の許容差と、何を再構築できるよう残すかを用途に応じて決める。

付録 再計算方法と参照資料

再計算用ファイル

ファイル	内容
run_experiment.py	元ログ生成から三評価、削除、出現情報による再学習まで実行する
verify_after_deletion.py	既存の結果を監査。削除済み元データを再生成しない
experiment/result.json	評価数値、合否、保持状況、容量、削除後確認の全結果
experiment/case_records_*.csv	事例ごとの出現情報、正解、条件、版、現行の元データ保存先
experiment/raw_manifest_*.csv	削除前後の対応表。履歴の保存先とハッシュは監査用
experiment/deletion_history.csv	削除した1,221件の識別情報と監査記録
experiment/raw/	削除後に残った元ログ。学習411件、確立度1,632件、最終評価3,792件
experiment/*.joblib	比較基準モデル、出現情報モデル、削除後再学習モデル

Python 3.12.14で実行。NumPy 2.3.5、pandas 2.2.3、SciPy 1.17.0、scikit-learn 1.8.0、joblib 1.5.3。requirements.txtに固定した。

監査は python verify_after_deletion.py experiment 。再生成を含む全実行は python run_experiment.py --output new_experiment 。出力先が存在する場合は停止し、以前の実験を上書きしない。

再計算コードには生成方法があるが、削除後の運用が過去の元データを復元できるという意味ではない。最終評価結果を受けたパラメータ調整は行っていない。出力形式と参照更新を修正して同じ乱数・同じ設定で再実行し、指標が一致することを確認した。

利用した既存手法の公式資料

DBSCAN
https://scikit-learn.org/1.8/modules/generated/sklearn.cluster.DBSCAN.html

標準化
https://scikit-learn.org/1.8/modules/generated/sklearn.preprocessing.StandardScaler.html

ロジスティック回帰
https://scikit-learn.org/1.8/modules/generated/sklearn.linear_model.LogisticRegression.html

二項比率の正確区間とWilson区間
https://docs.scipy.org/doc/scipy/reference/generated/scipy.stats._result_classes.BinomTestResult.proportion_ci.html